

OS4MAS/OF4MAS/13E054MAS -2014
Metode analize elektrofizioloških signala
CIKLUS II: 3. Predavanje

Automatsko prepoznavanje R-talasa u EKG signalu

Materijal za ovo predavanje je preuzet iz Magistarskog rada:


“Osnovni mehanizmi u kardiovaskularnom sistemu i EKG signal”

Dubravka Bojanić, Tehnički fakultet, Novi Sad, 2003.

A. EKG signal

„Normalni“ EKG je ponovljiv složenoperiodični signal u kome razlikujemo nekoliko karakterističnih oblika koje nazivamo talasi. Normalni EKG je ponovljiv signal pa možemo da ga opišemo koristeći parametre u vremenskom i frekvencijskom domenu. Koristeći ovakav opis možemo automatski odrediti nepravilnost u slučaju poremećaja rada srčanog mišića.

Osnovne komponente EKG signala su P talas, QRS kompleks i T talas, Slika 1. QRS kompleks je dominantni deo EKG signala. Na osnovu vremena u kojima se javlja i oblika QRS kompleksa dobijaju se značajne informacije o stanju srca. QRS komplekse koristimo za određivanje srčanog ritma, za klasifikaciju srčanih ciklusa i kao polaznu tačku u algoritmima za kompresiju EKG signala, što znači da je detekcija QRS kompleksa u osnovi gotovo svih algoritama za automatsku obradu EKG signala.



Slika 1. Karakteristični intervali u EKG signalu: **RR interval** - predstavlja rastojanje između 2 susedna R pika i služi za određivanje komorskog ritma. **PP interval** - predstavlja rastojanje između 2 susedna P talasa i služi za određivanje pretkomorskog ritma. **PR interval** - obuhvata vreme potrebno za depolarizaciju pretkomora, kašnjenje sprovođenja u AV čvoru i prolazak impulsa kroz Hisov snop i njegove grane, sve do nastanka depolarizacije komora. Meri se od početka P talasa do početka QRS kompleksa. Normalne vrednosti su od 0.12-0.20s, najčešće je 0.16s i zavisi od srčane frekvencije (što je frekvencija manja to je PR interval duži). **QRS interval** - predstavlja vreme depolarizacije komora. Meri se od početka Q talasa (ili R ukoliko Q nije vidljiv) do kraja S talasa. Gornje granice su 0.10-0.11s. **Vreme aktivacije komora (VAT)** - vreme potrebno impulsu da prođe kroz miokard od njegove endokardne do epikardne površine. To je rastojanje od početka Q zupca do vrha R zupca i iznosi oko 0.03s. **QT interval** - meri se od početka Q talasa do kraja T talasa i predstavlja trajanje sistole (kontrakcije) komora. Obično traje 0.35s, a zavisi od srčane frekvencije. **QU interval** - meri se od početka Q talasa do kraja U talasa i predstavlja vreme repolarizacije komora, uključujući i repolarizaciju Purkinjeovih vlakana.

B. QRS KOMPLEKS I PROBLEMI PRI NJEGOVOJ DETEKCIJI

Komponente EKG signala (P talas, QRS kompleks, T talas) imaju spektralne karakteristike koje se menjaju u vremenu. Frekvencijski opseg signala je 0.05-100 Hz, a amplitude su od 1-10mV. Kratkotrajni QRS kompleks je najdominantniji deo u normalnom EKG signalu.

Na osnovu vremenskih trenutaka u kojima se javljaju i oblika QRS kompleksa može se doći do značajnih informacija o stanju srca. QRS kompleksi koriste se za određivanje srčanog ritma, za klasifikaciju srčanih ciklusa i kao polazna tačka u algoritmima za kompresiju EKG signala, što znači da je detekcija QRS kompleksa u osnovi gotovo svih algoritama za automatsku obradu EKG signala.

Međutim, detekcija QRS kompleksa, odnosno R pika u EKG signalu je složen problem iz više razloga i to: 1) spektralne karakteristike komponenti signala zavise od fizioloških promena i od pacijenta, 2) ponekad P i T talas mogu imati karakteristike slične karakteristikama QRS kompleksa i 3) postoje mnogi izvori šumova u kliničkom okruženju koji degradiraju EKG signal (power line interferencija, šum usled kontrakcije mišića - EMG šum, loš kontakt elektroda sa telom, pomeranje elektroda, pokretanje pacijenta, baseline šum usled respiracije). Osim toga, treba voditi računa o tome da EKG aparat bude pravilno standardizovan tako da 1mV daje defleksiju od 1cm, jer pogrešna standardizacija daje netačnu voltažu kompleksa što vodi u netačnu interpretaciju zapisa.

C. DIJAGNOSTIČKI ZNAČAJ EKG ZAPISA


EKG ima dijagnostički značaj u sledećim kliničkim okolnostima:

- poremećaji funkcionisanja vodiča ritma (SA čvora) kada ulogu vodiča ritma preuzima neki drugi (ektopički) pacemaker koji može biti u pretkomorama, u AV čvoru ili u komorama; posledica ovoga je promena srčane frekvencije što se lako prepoznaje na EKG zapisu,
- određivanje porekla, klasifikacija (promenljivi ritam, tahikardija, bradikardija, ekstrasistole i preskoci, srčani blokovi, fibrilacija komora, fibrilacija pretkomora) i praćenje aritmija,
- hipertrofija (povećanje debljine zida) komora i pretkomora,
- usporeno sprovođenje električnih impulsa kroz pretkomore i komore,
- ishemija i infarkt miokarda,
- perikarditis,
- sistemska oboljenja srca,
- određivanje dejstva lekova, naročito digitalisa i nekih antiaritmika,
- poremećaj ravnoteže elektrolita, naročito kalijuma, itd.

Svaka od ovih bolesti i poremećaja odražava se na određeni način na EKG zapisu i njegovom interpretacijom moguće je brzo postaviti tačnu dijagnozu.

D. Metode za detekciju QRS kompleksa

Razvoj softvera za obradu EKG signala započet je pre više od 30 godina, a velika poboljšanja u kvalitetu algoritama ostvarena su zahvaljujući brzom razvoju kompjuterske tehnologije. Predloženi su mnogi algoritmi za automatsku dijagnostiku i to za detekciju QRS kompleksa, za detekciju P i T talasa, za detekciju i analizu zakasnelih potencijala, proučavanje aritmija i njihovu klasifikaciju, za izdvajanje raznih tipova poremećaja od korisnog signala, za proučavanje varijabilnosti srčanog ritma. Na samom početku razvoja softvera za detekciju QRS kompleksa u EKG signalu predložena je struktura koja je i danas u osnovi mnogih algoritama. Ta struktura prikazana je na Slici 2, a sastoji se iz faze preprocesiranja i faze odlučivanja. Preprocesiranje podrazumeva linearno i nelinearno filtriranje, a faza odlučivanja uključuje logiku za detekciju pikova, donošenje odluke koji od pikova je QRS kompleks i određivanje trenutka pojave pika.



Slika 2. Zajednička struktura QRS detektora

E. Primeri metoda za detekciju QRS kompleksa

Navešćemo 11 metoda, kao i nekoliko njihovih varijanti.

1. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA IZVODIMA SIGNALA I DIGITALNIM FILTRIMA

QRS kompleks ima frekvencijske komponente u opsegu od 6-30 Hz, te većina konvencionalnih metoda za detekciju QRS kompleksa podrazumevaju filtriranje EKG signala pomoću filtara propusnika niskih učestanosti (LP), filtara propusnika visokih učestanosti (HP) i notch filtara [3, 8]. Propusni opseg LP filtra mora biti takav da se postigne kompromis između redukcije šuma i gubitka visokofrekventnih komponenti signala. Ako je širina propusnog opsega prevelika onda nije dovoljno dobro isfiltriran šum, a ako je premala gube se visokofrekventne komponente signala. Notch filtri se koriste za redukciju šuma na 50 Hz, a HP filtri za izdvajanje visokofrekventnih komponenti QRS kompleksa, te potiskivanje drugih komponenti signala kao što su P talas i T talas i za redukciju šuma tipa baseline drifta. U slučaju da se koriste samo HP filtri, filtrirani signal služi za generisanje tzv. feature signala, a detekcija QRS kompleksa se svodi na poređenje feature signala sa fiksnim ili adaptivnim pragom (*threshold*). Kombinovanjem LP i HP filtara dobija se filter propusnik opsega (BP), čije granične učestanosti treba da budu oko 6 Hz i 30 Hz. Gotovo svi algoritmi ovog tipa sadrže dodatna pravila odlučivanja kako bi se redukovao broj pogrešno detektovanih QRS kompleksa. Osim filtara koriste se i klizeći prozori [4], čije karakteristike treba da budu takve da se postigne kompromis između pogrešno detektovanih i nedetektovanih QRS kompleksa.

ALGORITMI KOJI SE BAZIRAJU NA IZVODIMA SIGNALA

U starijim algoritmima HP filtri su najčešće realizovani kao diferencijatori, pri čemu je za detekciju QRS kompleksa iskorišćena činjenica da oni imaju veći nagib u poređenju sa drugim segmentima EKG signala. Za realizaciju filtra predložene su [17, 77, 78, 79] sledeće diferencne jednačine:

$$y_1(n) = x(n+1) - x(n-1) \quad (1)$$

$$y_1(n) = 2x(n+2) + x(n+1) - x(n-1) - 2x(n-2) \quad (2)$$

$$y_1(n) = x(n) - x(n-1) \quad (3)$$

$$y_1(n) = \tilde{x}(n+1) - \tilde{x}(n-1) \quad (4)$$

gde je:

$$\tilde{x}(n) = \begin{cases} |x(n)|, & |x(n)| \geq \Theta \\ \Theta, & |x(n)| < \Theta, \end{cases} \quad (5)$$

Θ - amplitudski prag koji se određuje na osnovu izmerenog EKG signala $x(n)$.

Najčešće se koristi diferencijator definisan jednačinom (1). U nekim algoritmima [77], računa se i drugi izvod i procenjuje se kao:

$$y_2(n) = x(n+2) - 2x(n) + x(n-2) \quad (6)$$

Feature signal se može definisati na sledeće načine:

- kao izvod signala [78,79]:

$$z(n) = y_1(n) \quad (7)$$

- kao kombinacija apsolutnih vrednosti prvog i drugog izvoda [77]:

$$z(n) = \tilde{y}_1(n) + |y_2(n)| \quad (8)$$

gde je $\tilde{y}_1(n) = \{0.25, 0.5, 0.25\} * |y_1(n)|$, a $*$ označava linearnu konvoluciju.

Detekcija QRS kompleksa realizuje se poređenjem feature signala i praga. Vrednost praga zavisi od signala koji se analizira, te se tokom obrade signala vrši i adaptacija praga. U slučaju da je feature signal definisan kao u jednačini (7), predloženo je da se adaptacija praga vrši na sledeći način [78,79]:

$$\Theta_x = 0.3 \dots 0.4 \max [x] \quad (9)$$

Maksimum se određuje *online* ili iz tekućeg segmenta signala. Većina QRS detektora koristi ovakav ili sličan metod za određivanje praga.

U cilju smanjenja broja pogrešno detektovanih QRS kompleksa, faza odlučivanja, osim logike za detekciju pikova, sadrži i dodatna pravila odlučivanja koji od potencijalnih QRS kompleksa je pravi, pri čemu se uzima u obzir trenutak pojave i znak feature signala.

ALGORITMI KOJI SE BAZIRAJU NA DIGITALNIM FILTRIMA

U ovom poglavlju biće opisani neki algoritmi koji su realizovani pomoću digitalnih filtara.

U [17] predložen je algoritam u kome se EKG signal filtrira paralelno pomoću dva različita LP filtra sa različitim graničnim frekvencijama. Razlika izlaznih signala iz ova dva filtra je signal $y_1(n)$, koji se dalje procesira na sledeći način:

$$y_2(n) = y_1(n) \left[\sum_{k=-m}^m y_1^2(n+k) \right]^2 \quad (10)$$

Ovakvom nelinearnom operacijom postignuto je potiskivanje malih vrednosti i neznatno izravnavanje pikova. Feature signal $z(n)$ se formira na osnovu signala $y_2(n)$ uz dodavanje znaka koji je određen izlaznim signalom iz LP filtra sa većom graničnom frekvencijom. Prag se računa adaptivno kao $\Theta = \max [z(n)] / 8$.

U [18] i [19] predložen je MOBD (*Multiplication of Backward Difference*) algoritam. MOBD N -tog reda definiše se kao:

$$z(n) = \prod_{k=0}^{N-1} |x(n-k) - x(n-k-1)| \quad (11)$$

Kako bi se izbegle velike vrednosti feature signala $z(n)$ za vreme zašumljenih segmenata, uvodi se ograničenje:

$$z(n)=0 \text{ ako je } \text{sign}[x(n-k)] \neq \text{sign}[x(n-k-1)], \text{ gde je } k=0,1,\dots,N-2. \quad (12)$$

U [19] predloženo je da red MOBD algoritma bude $N = 4$. Prag Θ se postavlja na maksimalnu vrednost feature signala z_{max} po isteku *refractory* perioda, a potom se smanjuje 2 puta svaki put po isteku fiksnog vremenskog intervala. Postoji donja granična vrednost za Θ , koja se može menjati.

U [20] i [21] EKG signal se propušta kroz BP filtar, a potom diferencira. Feature signal $z(n)$ se formira kvadriranjem i usrednjavanjem signala koji se dobija na izlazu iz diferencijatora. Koeficijenti BP filtra i diferencijatora su prilagođeni implementaciji na *fixed-point* procesorima sa malom dužinom reči. U cilju detekcije pikova uvodi se promenljiva ν koja ima vrednost poslednjeg maksimuma feature signala. U feature signalu pikovi se detektuju tako što se on poredi sa ν i ako vrednost feature signala padne ispod $\nu/2$ detektuje se pik. Tada se za visinu pika uzima vrednost ν , a nova vrednost za ν postaje jednaka trenutnoj vrednosti feature signala $\nu = z(n)$. *Fiducial mark* se postavlja na lokaciji najvećeg pika u filtriranom signalu u intervalu od 225 ms do 125 ms pre detekcije pika. *Fiducial mark* i visina pika se smeštaju u vektor događaja koji se dalje obrađuje u fazi odlučivanja. U fazi odlučivanja estimira se nivo pika koji predstavlja QRS kompleks (L_P) i nivo šuma (L_N):

$$L_P(n) = \lambda_P \cdot L_P(n-1) + (1 - \lambda_P) \cdot A_P \quad (13)$$

$$L_N(n) = \lambda_N \cdot L_N(n-1) + (1 - \lambda_N) \cdot A_P \quad (14)$$

gde su λ_P i λ_N faktori zaboravljanja, a A_P amplituda pika. U zavisnosti od toga da li je pik klasifikovan kao QRS kompleks ili kao šum, računaju se nove vrednosti za L_P ili L_N prema jednačinama (13) ili (14). Prag se računa na sledeći način:

$$\Theta = L_N + \tau \cdot (L_P - L_N), \quad (15)$$

gde je τ koeficijent, i $0 < \tau < 1$.

U [22] feature signal $z(n)$ se računa slično kao u [20] i [21] s tim što se koriste drugačiji filtri. Ovde se feature signal deli na segmente od po 15 tačaka. Maksimum na svakom segmentu se poredi sa procenjenim vrednostima nivoa šuma i nivoa pika i onda se klasifikuje u jednu od ove dve klase. QRS kompleks se detektuje na lokaciji unutar QRS segmenta na kojoj se trenutak pojave maksimuma EKG signala poklapa sa trenutkom u kome prvi izvod signala menja znak.

U [23] za detekciju karakterističnih talasa u EKG signalu primenjen je algoritam koji se bazira na neuralnim mrežama. Za detekciju QRS kompleksa koristi se *feature extractor* koji se bazira na digitalnim filtrima. EKG signal se propušta kroz dva različita BP filtra, na čijim izlazima se dobijaju signali $w(n)$ i $f(n)$. Feature signal se dobija množenjem ova dva izlaza:

$$z(n)=w(n)f(n) \quad (16)$$

Ova procedura se bazira na pretpostavci da će se pojedine frekvencijske komponente QRS kompleksa pojaviti u isto vreme unutar propusnih opsega oba filtra. Feature signal će imati veliku vrednost samo ako oba izlaza imaju veliku vrednost i to će biti indicacija da se u tom trenutku javio QRS kompleks. Trenutak u kome feature signal ima maksimalnu amplitudu proglašava se za trenutak pojave R pika.

Algoritam koji koristi rekurzivne i nerekurzive median filtre predložen je u [24]:

$$y(n) = \text{median} [y(n-m), \dots, y(n-1), x(n), x(n+1), \dots, x(n+m)], \quad (17)$$

$$y(n) = \text{median} [x(n-m), \dots, x(n-1), x(n), x(n+1), \dots, x(n+m)]. \quad (18)$$

Kada se na vektor $\mathbf{x} = [x_1, \dots, x_N]$ primeni *median* operator, elementi vektora se sortiraju na osnovu njihove vrednosti, a za izlaz iz filtra se uzima vrednost $y = \mathbf{x}_{\text{sorted}}(N/2)$. U [24] BP filter se dobija kombinovanjem dva median filtra i jednog *smoothing* filtra. Procesiranje signala se dalje vrši slično kao u [20] i [21].

U [25] i [26] autori su za obradu EKG signala dali uopštenu formu filtra čija je funkcija prenosa:

$$H(z) = (1 - z^{-K})(1 + z^{-1})^L \quad K, L > 0. \quad (19)$$

Ovakvi filtri imaju linearnu faznu karakteristiku i veoma su efikasni kada je u pitanju računanje. Primenjeni su za detekciju QRS kompleksa u [27], sa konkretnim vrednostima parametara $K=1$ i $L=2$, i frekvencijom odabiranja $f_s=100$ Hz. i u [28], gde je $K=5$ i $L=4$, a frekvencija odabiranja $f_s=250$ Hz.

U ovom poglavlju dati su osnovni principi na kojima se baziraju algoritmi za detekciju QRS kompleksa uz pomoć digitalnih filtara. Digitalni filtri su upotrebljeni i u mnogim drugim algoritmima za detekciju QRS kompleksa, npr. [29, 30].

2. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA MATCHED FILTRIMA

U [70, 71, 72, 73] predloženi su algoritmi za detekciju QRS kompleksa pomoću linearnih mathed (prilagođenih) filtara. U [70] nakon analognog preprocesiranja (automatska kontrola pojačanja), EKG signal se digitalizuje i obrađuje pomoću LP filtra, notch filtra koji ne propušta 50 Hz i BP filtra sa graničnim učestanostima na 15 Hz i 40 Hz. Nakon ovog koraka, signal se propušta kroz matched filter u cilju maksimizacije odnosa signal/šum (SNR). Izlaz iz matched filtra $y(n)$ je:

$$y(n) = \sum_{i=0}^{N-1} h(i)x(n-i) \quad (20)$$

Impulsni odziv mathed filtra $h(n)$ ima oblik signala koji se analizira, inverzno u odnosu na vreme. Impulsni odziv se određuje ručno na osnovu prvog srčanog ciklusa tekućeg merenja i mora se određivati interaktivno. Kako bi se povećala tačnost određivanja trenutka pojave R pika, vrši se interpolacija na signalu koji se dobija na izlazu iz filtra tako da se frekvencija odabiranja povećava 4 puta. Konačna odluka o QRS kompleksu se donosi poređenjem filtriranog signala sa fiksnim pragom.

Sličan pristup predložen je u [72]. Umesto računanja kroskorelacije (20) ovde se računa AMCD (Average Magnitude Cross Difference) (21) i traži se minimum te funkcije.

$$AMCD = \sum_{i=1}^N |x(n-i) - h(i)| \quad (21)$$

$x(n)$ - EKG signal, a $h(i)$ - template koji ima oblik signala, ali je invertovan u vremenu. Pošto nema operacija množenja, algoritam je efikasan kada je u pitanju računanje. Autori su radili sa dužinama template-a $N=10$ i 20 , a frekvencija odabiranja je bila 500 Hz. Pre računanja AMCD funkcije moraju se ukloniti trendovi iz EKG signala i template-a.

U [73] korišćena su integralna kola koja omogućavaju računanje korelacionih koeficijenata u realnom vremenu.

3. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA ADAPTIVNIM FILTRIMA

Adaptivni predikcioni FIR filtri primenjeni su za detekciju QRS kompleksa u [51] i [52]. Cilj je da se estimira trenutna vrednost signala $\hat{x}(n)$ na osnovu prethodnih vrednosti:

$$\hat{x}(n) = \sum_{i=1}^P a_i(n)x(n-i) \quad (22)$$

gde su $a_i(n)$, $i=1, \dots, P$ vremenski promenljivi koeficijenti filtra koji se prilagođavaju promenama statistike signala. Jedna od metoda za adaptaciju koeficijenata je LMS (Least Mean Square) algoritam:

$$\mathbf{a}(n+1) = \mathbf{a}(n) + \lambda e(n)\mathbf{x}(n) \quad (23)$$

gde su: $\mathbf{a}(n) = [a_1(n) \ a_2(n) \ \dots \ a_P(n)]^T$ - vektor koeficijenata u trenutku n ,

λ - step size parametar,

$e(n) = x(n) - \hat{x}(n)$ - greška predikcije i

$\mathbf{x}(n) = [x(n-1) \ x(n-2) \ \dots \ x(n-P)]^T$ - vektor zakašnjenih odbiraka EKG signala.

U [52] autori su predložili da se feature signal formira na osnovu koeficijenata adaptivnog filtra i to kao razlika između koeficijenata vektora \mathbf{a} u trenucima n i $n-1$:

$$D(n) = \sum_{i=1}^P |a_i(n) - a_i(n-1)|^2 \quad (24)$$

i kao razlika u energijama greške na dva susedna segmenta:

$$D_e(n) = \sum_{i=n}^{n+m} e^2(i) - \sum_{i=n-m}^n e^2(i) \quad (25)$$

U [53] pokazano je da se za $f_s = 500$ Hz, dobra predikcija ostvaruje korišćenjem dva *tap* filtra. U [54] za detekciju QRS kompleksa predložen je *midprediction* filter:

$$\hat{x}(n) = \sum_{k=-P}^P a_k x(n-k) \quad (26)$$

4. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA PRINCIPIIMA MATEMATIČKE MORFOLOGIJE

U oblasti obrade EKG signala, principi matematičke morfologije iskorišćeni su za detekciju QRS kompleksa u [55] i za uklanjanje impulsnog šuma iz EKG signala [56].

Matematička morfologija bazira se na terminima *erosion* i *dilatation*. Neka su $f: F \rightarrow \mathbb{I}$ i $k: K \rightarrow \mathbb{I}$ diskretne funkcije, $F = \{0, 1, \dots, N-1\}$, $K = \{0, 1, \dots, M-1\}$ i \mathbb{I} skup celih brojeva. Operacija *erosion* nad funkcijama f i k definiše se kao:

$$(f \ominus k)(m) = \min_{n=0, \dots, M-1} f(m+n) - k(n) \text{ za } N > M \text{ i } m=0, \dots, N-M. \quad (27)$$

Funkcija k se naziva strukturni element. Vrednosti $(f \ominus k)$ su uvek manje od vrednosti funkcije f .

Operacija *dilatation* funkcije f funkcijom k definiše se kao:

$$(f \oplus k)(m) = \max_{n=0, \dots, M-1} f(n) + k(m-n) \text{ za } N > M \text{ i } m=M-1, \dots, N-1. \quad (28)$$

Vrednosti $(f \oplus k)$ su uvek veće od vrednosti funkcije f .

Kombinovanjem osnovnih operacija (*erosion* i *dilatation*) dobijaju se nove operacije. *Opening* (otvaranje) označava se sa \circ i označava operaciju *erosion* koja je praćena operacijom *dilatation*. *Closing* (zatvaranje) označava se sa \bullet i označava operaciju *dilatation* koja je praćena operacijom *erosion*. Na primer, otvaranje sekvence f nekim ravnim strukturnim elementom k ukloniće sve pikove, a zatvaranje istim strukturnim elementom ukloniće negativne pikove.

U [55] predložen je algoritam za detekciju QRS kompleksa u kome se operacije otvaranja i zatvaranje koriste za potiskivanje šumova na način opisan u [56]:

$$\tilde{x} = \frac{[(x \circ k) \bullet k] + [(x \bullet k) \circ k]}{2} \quad (29)$$

gde je k ravan strukturni element (nulta linija). Generisanje feature signala za detekciju QRS kompleksa se vrši po formuli:

$$z = \tilde{x} - [(\tilde{x} \circ B) \bullet B] \quad (30)$$

gde je B strukturni element u vidu pika. U [55] B je dužine 13 odbiraka. QRS kompleks se pronalazi poređenjem feature signala sa adaptivnim pragom.

5. GENETIC ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA

Genetic algoritmi su procedure za optimizaciju koje obezbeđuju vrlo efikasno pronalaženje optimalnih parametara. U [57], genetic algoritam je primenjen u fazi projektovanja optimalnog polinomijalnog filtra za preprocesiranje EKG signala i za podešavanje parametara u fazi odlučivanja. Kako bi se postigla maksimalna efikasnost, na ulaz filtra se dovodi vrlo mali broj odbiraka koji se, takođe biraju pomoću genetic algoritma.

Polinomijalni filtri definišu se kao:

$$y_n = \sum_{k_1=0}^M \sum_{k_2=0}^M \dots \sum_{k_N=0}^M \underbrace{a_{k_1 k_2 \dots k_N}}_{\sum k_j \leq M} x_{n-d_1}^{k_1} x_{n-d_2}^{k_2} \dots x_{n-d_N}^{k_N} \quad (31)$$

gde su d_j kašnjenja u odnosu na trenutak n , M je red filtra, a N je broj ulaznih odbiraka signala.

U fazi odlučivanja pikovi se detektuju tako što se filtrirani EKG signal poredi sa adaptivnim pragom. Parametri koji određuju prag se optimizuju zajedno sa parametrima polinomijalnog filtra pomoću genetic optimizacionog algoritma, pri čemu je kriterijum performanse formiran na osnovu tačno detektovanih QRS kompleksa u skupu referentnih EKG signala iz MIT-BIH Arrhythmia baze.

Proveravane su performanse tri specijalna slučaja polinomijalnih filtara na 48 EKG signala iz MIT-BIH Arrhythmia baze i to:

- kvazi-linearni filtri sa susednim odbircima ($M=1$, $N=10$),
- kvazi-linearni filtri sa selektovanim odbircima ($M=1$, $N=5$), pri čemu koeficijenti d_j podležu optimizaciji i
- filtri drugog reda sa selektovanim odbircima ($M=2$, $N=3$).

6. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA HILBERTOVOJ TRANSFORMACIJI

Hilbertova transformacija realnog signala x definiše se kao:

$$x_H(t) = \mathbf{H}\{x\} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{x(\tau)}{t - \tau} d\tau = x(t) * \frac{1}{\pi t} \quad (32)$$

U frekvencijskom domenu računa se kao:

$$X_H(j\omega) = X(j\omega) \cdot [-j \cdot \text{sgn}(\omega)] = X(j\omega) \cdot H(j\omega) \quad (33)$$

pri čemu je prenosna funkcija Hilbertove transformacije:

$$H(j\omega) = \begin{cases} -j, & 0 \leq \omega < \pi \\ j, & -\pi \leq \omega < 0 \end{cases} \quad (34)$$

Korišćenjem FFT, Hilbertova transformacija se lako računa.

U [58] predložen je algoritam za detekciju QRS kompleksa korišćenjem Hilbertove transformacije gde je idealna Hilbertova transformacija aproksimirana FIR filtrom čiji je impulsni odziv $h(n)$. HT $x_H(n)$ EKG signala $x(n)$, koristi se za računanje envelope koja se

za signale ograničenog spektra računa kao:

$$x_e(n) = \sqrt{x^2(n) + x_H^2(n)}. \quad (35)$$

Aproksimacija envelope koja je jednostavnija za računanje data je formulom:

$$x_e(n) \approx |x(n)| + |x_H(n)|. \quad (36)$$

Kako bi se uklonilo talasanje envelope i nejasnoće u određivanju nivo pikova, envelope $x_e(n)$ se propušta kroz LP filter. Predložen je i metod za potiskivanje niskofrekventnih komponenti u EKG signalu.

U [59] predložen je metod kod koga se envelope signala računa kao:

$$x_e(n) \approx |x_I(n)| + |x_2(n)|. \quad (37)$$

gde su $x_I(n)$ i $x_2(n)$ izlazi iz dva ortogonalna digitalna filtra:

$$x_I(n) = x(n) - x(n-6), \quad (38)$$

$$x_2(n) = x(n) - x(n-2) - x(n-6) - x(n-8). \quad (39)$$

U cilju uklanjanja šumova, envelope $x_e(n)$ se "pegla" pomoću MA filtra sa 4 *tapa*.

7. SINTAKTIČKI ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA

Sintaktički algoritmi za detekciju QRS kompleksa predloženi su u [62, 63, 65, 66]. Pretpostavlja se da se signal koji se analizira može predstaviti pomoću nekoliko međusobno povezanih osnovnih oblika - primitiva ili stringova. Sintaktički algoritmi za prepoznavanje oblika zahtevaju definisanje osnovnih oblika (primitiva), odgovarajuće lingvističke reprezentacije primitiva i gramatike.

EKG signal se deli na kratke segmente promenljive ili fiksne dužine. Svaki segment se predstavi pomoću primitiva i onda kodira korišćenjem unapred definisanog alfabeta. U većini algoritama, primitivi pomoću kojih se predstavlja signal su linijski segmenti [62,64], a u [66] ovakav skup primitiva proširen je pikovima, parabolama i drugim atributima. U [64, 66, 67, 68, 69] predložene su različite gramatike za ovakve alfabete.

8. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA MAP ESTIMACIJI

Maximum a posteriori (MAP) estimacija je metoda za estimaciju parametara koja uključuje prethodno znanje. MAP estimacija $\hat{\theta}_{MAP}$ parametra θ na osnovu opservacije \mathbf{x} , definiše se kao:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} f_{\theta}(\theta | \mathbf{x}) \quad (40)$$

$$f_{\theta}(\theta | \mathbf{x}) = \frac{f_x(\mathbf{x} | \theta) f_{\theta}(\theta)}{f_x(\mathbf{x})} \quad (41)$$

$f_{\theta}(\theta | \mathbf{x})$ je uslovna, aposteriorna funkcija gustine verovatnoće parametra θ . Apriorna funkcija gustine verovatnoće parametra θ , $f_{\theta}(\theta)$ predstavlja dostupno apriorno znanje o θ .

U [25] je opisan algoritam za detekciju QRS kompleksa koji se bazira na MAP estimaciji. Odbirci EKG signala smeštaju se u N -dimenzionalni vektor na sledeći način:

$$x(n) = \begin{cases} B_i s(n - \theta_i, T_i) + w(n), & 1 \leq q \leq k \\ w(n), & q = 0 \end{cases} \quad (42)$$

gde su: q - broj pikova oblika $s(n, T)$ na EKG segmentu i u vektoru \mathbf{x} ,

k - broj svih pikova na datom segmentu,

B_i - amplituda i-tog pika, $i=1, \dots, k$,

T_i - trajanje i-tog pika,

θ_i - trenutak pojave i-tog pika,

$w(n)$ - aditivni beli Gausov šum.

Za datu združenu apriornu funkciju gustine verovatnoće $f_{q, B, T, \theta}(q, \mathbf{B}, \mathbf{T}, \theta)$, MAP estimacija parametara je:

$$(\hat{q}, \hat{\mathbf{B}}, \hat{\mathbf{T}}, \hat{\theta}) = \arg \max_{q, \mathbf{B}, \mathbf{T}, \theta} V(\mathbf{x}, q, \mathbf{B}, \mathbf{T}, \theta) \quad (43)$$

gde je $V(\mathbf{x}, q, \mathbf{B}, \mathbf{T}, \theta)$ - log-likelihood (verodostojnost) funkcija u odnosu na $f_{q, B, T, \theta}(q, \mathbf{B}, \mathbf{T}, \theta)$.

Proces maksimizacije je zahtevan kada je u pitanju računanje, tako da su autori dali i modifikaciju aproksimacije MAP estimacije. Ostala pojednostavljenja data su u [26].

9. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA TRANSFORMACIJI DUŽINE I ENERGIJE

Algoritmi za detekciju QRS kompleksa koji se baziraju na transformaciji dužine i energije opisani su u [60] i [61]. Ove transformacije se definišu za višekanalne EKG signale, ali se mogu koristiti i za analizu jednokanalnog EKG signala. Transformacija dužine data je kao:

$$L(n, q, i) = \sum_{k=i}^{i+q-1} \sqrt{\sum_{j=1}^n (\Delta x_{j,k})^2}, \quad (44)$$

a transformacija energije:

$$E(n, q, i) = \sum_{k=i}^{i+q-1} \sum_{j=1}^n (\Delta x_{j,k})^2 \quad (45)$$

gde su: n - broj EKG kanala,

i - vremenski indeks,

q - dužina prozora i

$\Delta x_{j,k} = x_{j,k} - x_{j,k-1}$.

Prethodne dve formule se baziraju na pretpostavci da se izvodi EKG signala mogu posmatrati kao elementi vektora, pri čemu svaki element odgovara određenom odvodu sa koga je sniman signal. Dužina vektora određena je kvadratnim korenom druge sume u jednačini (44). Transformacija dužine predstavlja *temporarily smoothed time course of the vector length*. Transformacija energije može da se protumači kao estimacija energije vektora u kratkom vremenskom intervalu. Autori radova [60] i [61] zaključili su da su ove transformacije superiorne u odnosu na konvencionalne transformacije koje se koriste za izdvajanje feature-a. Transformacija dužine daje dobre rezultate za male QRS komplekse.

10. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA NEURALNIM MREŽAMA

Neuralne mreže (Neural Networks-NN) predstavljaju novu generaciju sistema za informaciono procesiranje koje imaju osobine učenja, memorisanja i generalizacije na osnovu podataka kojima se obučavaju. Do razvoja neuralnih mreža došlo je iz razloga što je postojala motivacija da se modeluje ponašanje neurona u mozgu. One se sastoje od velikog broja gusto povezanih procesorskih elemenata (čvorova, neurona) koji uobičajeno rade u paraleli i koji su organizovani po nekim regularnim arhitekturama. Veštačke neuralne mreže su vrlo efikasne u zadacima kao što su: mečovanje i klasifikacija oblika, aproksimacija funkcija, optimizacija, vektorska kvantizacija, klasterizacija podataka i dr. U ovim aplikacijama njihove performanse su superiorne u poređenju sa konvencionalnim računarskim algoritmima.

Za obradu EKG signala najčešće se koriste:

- MLP (Multilayer perceptron),
- RBF (Radial Basis Function) i
- LVQ (Learning Vector Quantization) mreže.

MLP mreža sastoji se iz neurona koji su međusobno povezani i organizovani u više slojeva. Prvi sloj je ulazni sloj i on ima ulogu da ulazne signale multiplicira onoliko puta kolike su potrebe prvog sledećeg sloja. Izlazi iz mreže se generišu iz izlaznog sloja. Slojevi između ulaznog i izlaznog nazivaju se skriveni slojevi. Informacija koju procesira i -ti čvor se može podeliti na ulazni i izlazni signal, a veza između ovih signala predstavljena je integracionom funkcijom f_i . Čest oblik funkcije f_i je:

$$f_i = \sum_{j=1}^N w_{ij} x_j - \Theta_i \quad (46)$$

gde su: Θ_i – prag i -tog čvora,

w_{ij} - težinski koeficijent, odnosno snaga veze između neurona j (izvora) i neurona i (destinacije),

x_j – ulazni signali.

Sledeća aktivnost elementa za procesiranje jeste da zbirni reprezent ulaznih signala f_i prenese do izlaza čvora u obliku izlaznog signala. Za to je zadužena aktivaciona funkcija $a(f)$. Neke često korišćene aktivacione funkcije su:

unipolarna sigmoidna $a(f) = 1/(1 + e^{-\lambda f})$ i $a(f) = \tanh(f)$

Kod RBF mreža aktivacione funkcije neurona u skrivenom sloju su Gausove funkcije, te je izlaz iz k -tog neurona koji se nalazi u izlaznom sloju RBF mreže:

$$y_k = \sum_{j=0}^p w_{jk} \phi_j = \sum_{j=1}^p w_{jk} \phi_j + w_{0k} \quad (47)$$

gde su: ϕ_j - bazična funkcija, $\phi_j = \exp(-\|\mathbf{x} - \mathbf{m}_j\|^2 / 2\sigma_j^2)$ i $\phi_0 = 0$,

w_{ij} - težinski koeficijent odnosno snaga veze između neurona j (izvora) i neurona i

(destinacije),
 \mathbf{x} - ulazni vektor podataka,
 \mathbf{m}_j - prototip vektor za j -ti klaster,
 σ_j - standardna devijacija karakteristična za j -ti klaster,
 $\|\mathbf{x} - \mathbf{m}_j\|$ - Euklidsko rastojanje između \mathbf{x} i \mathbf{m}_j .

Eksponencijalna funkcija može da se zameni nekim drugim funkcijama, npr. waveletima. RBF mreže su blisko povezane sa metodama fuzzy-logike. Prednost RBF u odnosu na MLP mreže je mogućnost interpretacije parametara zbog njihove veze sa metodama fuzzy-logike. Rezultati se zbog toga mogu bolje predvideti, te su i pouzdaniji.

LVQ mreža se sastoji iz ulaznog, konkurentnog i linearnog sloja. Konkurentni sloj automatski klasifikuje ulazne vektore na podklase, gde je maksimalni broj podklasa N jednak broju neurona u konkurentnom sloju. Klasifikacija se ovde vrši na bazi Euklidskog rastojanja između ulaznog vektora i težinskih vektora neurona u konkurentnom sloju. Linearni sloj kombinuje podklase i dobijaju se korisnički definisane ciljne klase.

Da bi se neuralna mreža mogla upotrebiti za izvršenje nekog konkretnog zadatka, potrebno je definisati pravilo za obučavanje, te izvršiti njeno obučavanje. Obučavanje podrazumeva podešavanje težinskih koeficijenata u neuralnoj mreži (parametarsko obučavanje) ili promenu strukture mreže, broja slojeva i broja čvorova u njima (strukturno obučavanje). Kod MLP i RBF mreža koristi se tzv. supervizirano obučavanje (obučavanje sa učiteljem koje je analogno klasifikaciji sa obučavajućim skupom gde se poseduju uzorci iz svih klasa i gde se klasifikator projektuje tako da se izvrši jasna separacija oblika iz različitih klasa). Kod LVQ mreža se koristi nesupervizirano obučavanje koje je analogno klasterizaciji u prepoznavanju oblika gde se iz ukupnog skupa uzoraka ne zna koji uzorak pripada kojoj klasi.

Neki algoritmi za klasifikaciju karakterističnih talasa u EKG signalu korišćenjem neuralnih mreža opisani su u [43, 23, 44, 45, 46, 47, 48, 49, 50]. Neki od ovih algoritama odnose se i na detekciju QRS kompleksa [45, 47, 49, 50].

NEURALNE MREŽE KAO ADAPTIVNI NELINEARNI PREDIKTORI

U algoritmima za detekciju QRS kompleksa, neuralne mreže se koriste kao adaptivni nelinearni prediktori [45, 49], pri čemu je cilj da se na osnovu prethodnih vrednosti signala $x(n-i)$, $i > 0$ proceni trenutna vrednost $x(n)$.

Ako se EKG signal podeli na segmente, postojaće mogobrojni segmenti na kojima nema QRS kompleksa i mnogo manji broj segmenata na kojima se dešavaju brze promene signala tj. na kojima je prisutan QRS kompleks. Na delovima gde nema iznenadnih promena signala, vrednosti odbiraka se mogu predvideti sa malom greškom predikcije, dok su segmenti na kojima postoje brze promene signala okarakterisani drugačijom statistikom, pa se javlja nagli porast greške predikcije $e(n)$. To znači da greška predikcije može da se iskoristi kao feature signal za detekciju QRS kompleksa.

Zbog nelinearne prirode šumova koji su prisutni u EKG signalu, nelinearni predikcioni filtri imaju bolje performanse u poređenju sa linearnim. U radovima [45, 49], projektovana je MLP mreža sa tri nivoa. Ulazni nivo sastoji se od 8-10 linearnih neurona čiji su ulazi vremenski zakašnjeni odbirci signala. Skriveni nivo ima 3-5 nelinearnih neurona, a izlazni nivo sadrži 1 linearni neuron. U [49] mreža se pre detekcije obučava na pažljivo izabranim odbircima. U [45] mreža se obučava online, te postoji mogućnost prilagođavanja promenama statistika signala. Izlaz iz nelinearnog predikcionog filtra se dodatno procesira pomoću matched filtra, čime se obezbeđuje bolje potiskivanje šumova.

PRIMENA LVQ NEURALNIH MREŽA ZA DETEKCIJU QRS KOMPLEKSA

U [50] autori su predložili LVQ mrežu za detekciju QRS kompleksa koja ima mogućnost razlikovanja preuranjenih kontrakcija komora (PVC) i normalnih QRS kompleksa. Ulazni i konkurentni sloj se sastoje od 20-40 neurona, a linearni sloj sadrži 2 neurona jer postoje dve izlazne klase. Ulazi u mrežu su susedni odbirci EKG signala. Obučavajući skup podataka formiran je na osnovu nekoliko zapisa iz MIT-BIH baze EKG signala. Rezultati dobijeni ovom metodom nisu dobri u poređenju sa rezultatima klasičnih metoda. Međutim, kada se LVQ mreža jednom obuči, algoritam je dalje vrlo brz i omogućava razlikovanja normalnih QRS kompleksa i PVC kontrakcija.

11. ALGORITMI ZA DETEKCIJU QRS KOMPLEKSA KOJI SE BAZIRAJU NA WAVELET TRANSFORMACIJI

Konstantna širina propusnog opsega filtra nije primerena analizi QRS kompleksa čije se frekvencijske komponente menjaju, a konstantna širina prozora ne odgovara promenama trajanja QRS kompleksa. Zato je primereniji adaptivni algoritam koji će podržati promene spektra u vremenu, a jedan od takvih je i dyadic wavelet transformacija [5, 9].

Wavelet transformacija je metoda za digitalnu obradu signala koja obezbeđuje izdvajanje korisnog signala iz zašumljenog i njegovu analizu. WT je primenjena za analizu EKG signala i to: za detekciju QRS kompleksa [9, 10, 11], za detekciju P i T talasa [10], za detekciju i analizu zakasnelih potencijala [5], proučavanje aritmija i njihovu klasifikaciju [11, 12, 31], za izdvajanje raznih tipova poremećaja od korisnog signala [13], za proučavanje varijabilnosti srčanog ritma [14].

TEORIJA WAVELET TRANSFORMACIJE I DETEKCIJA SINGULARITETA

Kontinualna wavelet transformacija (CWT) definiše se za kontinualni signal $x(t)$ [5]:

$$CWT_x(\tau, a) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} x(t) g^* \left(\frac{t - \tau}{a} \right) dt \quad (48)$$

gde su: $g(t)$ - osnovni wavelet, funkcija čiji je spektar ograničen i centriran oko f_0 ,
 τ - parametar translacije i
 a - faktor skaliranja, $a = f / f_0$.

Osnovni (mother) wavelet je funkcija koja ima karakterističan oblik, određenu širinu, odnosno trajanje u vremenskom domenu i odgovarajuću širinu spektra. Iz njega se izvode ostali wavelet-i koji imaju različite širine spektra i različite širine u vremenskom domenu (skalirani su sa odgovarajućim faktorom). U zavisnosti od faktora skaliranja osnovni wavelet se širi ili sabija. Primena CWT na signal može se posmatrati i kao njegovo propuštanje kroz grupu filtara propusnika opsega čije se centralne učestanosti i propusni opsezi menjaju u zavisnosti od faktora skaliranja. Ovako promenljiv propusni opseg odgovara različitim rezolucijama na različitim skalama, te CWT ima multirezolucione osobine.

Većina algoritama [9, 10, 33] za detekciju QRS kompleksa korišćenjem wavelet transformacije bazira se na Mallat-ovom i Hwang-ovom pristupu za detekciju singulariteta signala i njihovu klasifikaciju pomoću lokalnih maksimuma wavelet funkcije signala [32]. Oni su proučavali vezu između singulariteta signala $x(t)$ i lokalnih maksimuma njegove wavelet transformacije $CWT_x(\tau, a)$. Zaključili su da ako signal $x(t)$, na koji se primenjuje transformacija ili neki njegov izvod ima diskontinuitet, onda $|CWT_x(\tau, a)|$ ima lokalne maksimume na nekoliko susednih skala u trenutku pojave diskontinuiteta. Osnovni nedostatak CWT je složenost algoritma za izračunavanje. Analiza će biti mnogo efikasnija i jednako tačna ako se diskretizuju parametri τ , a ili oba. Ako se diskretizuje samo parametar a i to tako da on uzima vrednosti 2^i , $i=0,1,2,\dots$ onda CWT postaje DyWT [15]. Ako diskretizujemo i a i τ CWT postaje diskretna WT.

Dyadic wavelet transformacija signala $x(t)$ se definiše po formuli (49):

$$DyWT_x(\tau, 2^i) = \frac{1}{\sqrt{2^i}} \int_{-\infty}^{\infty} x(t) g^* \left(\frac{t-\tau}{2^i} \right) dt \quad (49)$$

U ovom slučaju wavelet funkcija mora da bude takva da se obezbedi pokrivanje cele frekvencijske skale, te da se signal $x(t)$ može rekonstruisati na osnovu njegove DyWT [15]. Pored toga što se znatno smanjuje složenost algoritma, DyWT zadržava većinu dobrih osobina CWT kao što su linearnost i dobra vremenska rezolucija brzopromenljivih komponenti signala. Za svaku skalu DyWT se izračunava kao konvolucija signala i izvedenog waveleta koji je skaliran u odnosu na osnovni za faktor 2^i . Za malo i , odnosno za male skale dobija se dobra vremenska, a lošija spektralna rezolucija (wavelet je sabijen u vremenskom domenu, a ima širok spektar i veliku centralnu učestanost) i služi za analizu visokofrekventnih komponenti signala. Za veće i , odnosno za veće skale dobija se lošija vremenska, a bolja spektralna rezolucija (wavelet je širi u vremenskom domenu, a spektar mu je uži i ima manju centralnu učestanost) i koristi se ako su potrebne precizne informacije o komponentama na nižim učestanostima.

Ako se wavelet funkcija izabere kao prvi izvod neke sporopromenljive funkcije (funkcije čija je glavnina energije na niskim frekvencijama), onda lokalni maksimumi funkcije $|DyWT_x(\tau, 2^i)|$ ukazuju na brze promene, a lokalni minimumi na spore promene signala. Znači, izborom odgovarajuće wavelet funkcije koja je pogodna za detekciju maksimuma i minimuma signala i izračunavanjem DyWT moguće je detektovati QRS komplekse na mestima gde su se pojavili maksimumi funkcije $|DyWT_x(\tau, 2^i)|$ na nekoliko sukcesivnih skala.

U cilju klasifikacije pikova računa se stepen singularnosti. Uvodi se promenljiva α - Lipschitz-ova regularnost, koja se estimira kao [32]:

$$\alpha_j = \log_2 |DyWT_x(n^{j+1}, 2^{j+1})| - \log_2 |DyWT_x(n^j, 2^j)| \quad (50)$$

$$\alpha = \frac{\alpha_1 + \alpha_2}{2}. \quad (51)$$

ALGORITMI KOJI SE BAZIRAJU NA DETEKCIJI SINGULARITETA

Rezultat do koga su došli Mallat i Hwang [32] za detekciju QRS kompleksa prvo su upotreбили autori u [10]. Oni su za pozicije R pikova proglašavali lokacije na kojima su se javljali lokalni maksimumi DyWT na 4 unapred izabrane skale, uz uslov da Lipschitz-ova regularnost mora biti veća od nule, $\alpha > 0$. Algoritam sadrži i dodatna pravila odlučivanja koja se odnose na znak i trenutak pojave pikova na različitim skalama.

Algoritam opisan u [33] je direktno izveden iz [10]. Znatno je pojednostavljen, ali su rezultati detekcije i dalje veoma dobri. Algoritam [10] implementiran je na digitalnim signal procesorima (DSP) u [34] i [35].

U [36] karakteristične tačke u EKG signalu se detektuju poređenjem koeficijenata diskretne wavelet transformacije za određene skale sa fiksnim thresholdom. U [37] EKG signal se deli na segmente fiksne dužine, a R pikovi se detektuju kada na susednim skalama maksimumi modula pređu threshold, pri čemu se threshold računa za svaki segment. U [9] je korišćen specifičan wavelet pogodan za analizu QRS kompleksa kod koga se skale adaptivno biraju na osnovu signala.

U ovom radu se DyWT računa za dve sukcesivne skale. Računanje na samo dve skale znatno ubrzava algoritam. Ovde prikazan QRS detektor je vrlo robustan u pogledu šuma i na promene spektra u vremenu.

FILTER-BANK ALGORITAM

Filter banks su blisko povezani sa waveletima. Njihova primena u detekciji QRS kompleksa opisana je u [16]. Autori su koristili grupu filtara za analizu i sintezu koji imaju linearnu faznu karakteristiku i veliko slabljenje u nepropusnom opsegu. Primenjeni filtri imaju istu širinu propusnog opsega i različite centralne učestanosti. Propusni opseg zavisi od frekvencije odabiranja i od frekvencijskog opsega u kome se nalazi većina spektralnih komponenti QRS kompleksa. Pomoću filtara za analizu vrši se dekompozicija EKG signala u 32 opsega, te se generišu downsampleovani signali u tim podopsezima. Filtri za sintezu omogućavaju rekonstrukciju signala.

Pretpostavljeno je da se QRS kompleks karakteriše istovremenom pojavom frekvencijskih komponenti u raznim podopsezima w_l , $l=1, \dots, 4$. Iz ovih podopsega izvode se tri feature signala p_1 , p_2 , p_3 :

$$p_1(n) = \sum_{l=1}^3 |w_l(n)| \quad (52)$$

$$p_2(n) = \sum_{l=1}^4 |w_l(n)| \quad (53)$$

$$p_3(n) = \sum_{l=2}^4 |w_l(n)| \quad (54)$$

Logika za detekciju QRS kompleksa sastoji se iz 5 nivoa na kojima se prave različite kombinacije feature signala na osnovu kojih se donosi odluka da li je neki pik QRS kompleks ili ne.

OSTALE PRIMENE WAVELET TRANSFORMACIJE U OBRADI EKG SIGNALA

WT je primenjena za analizu EKG signala i to, osim za detekciju QRS kompleksa: za detekciju P i T talasa [10] za detekciju i analizu zakasnelih potencijala [5] proučavanje aritmija i njihovu klasifikaciju [11, 12, 31] za izdvajanje raznih tipova poremećaja od korisnog signala [13, 41, 42] za proučavanje varijabilnosti srčanog ritma [14, 40] za kompresiju podataka [40].

LITERATURA

- [1] D. Popović, M. Popović, Biomedicinska instrumentacija i merenja, Nauka, Beograd, 1997.
- [2] A.C. Guyton, Medicinska fiziologija, Savremena administracija, Medicinska knjiga, Beograd, 1996.
- [3] L. T. Mainardi, A. M. Bianchi, S.Cerutti: "Digital biomedical signal acquisition and processing," in J. D. Bronzino (ed), The Biomedical Engineering Handbook, pp 828-852. CRC Press, Inc.,1995.,
- [4] A. Cohen: "Biomedical signals:origin and dynamic characteristics; Frequency-domain analysis," in J. D. Bronzino (ed), The Biomedical Engineering Handbook, pp 805-827. CRC Press, Inc.,1995.,
- [5] N. V. Thakor, D. Sherman: "Wavelet (time-scale) analysis in biomedical signal processing," in J. D. Bronzino (ed), The Biomedical Engineering Handbook, pp 886-906. CRC Press, Inc.,1995.,
- [6] A. Cohen, Biomedical signal processing: Time and Frequency Domain Analysis, Boca Raton, Fla, CRC Press, 1986.
- [7] A. Cohen, Biomedical signal processing: Compression and Automatic Recognition, Boca Raton, Fla, CRC Press, 1986.
- [8] J. A. Van Alsté, T. S. Schilder, " Removal of base- line wander and power-line interference from the ECG by an efficient FIR filter with a reduced number of taps," *IEEE Trans. Biomed. Eng.*, vol. BME-32, pp. 1052-1060, 1985.
- [9] S. Kadambe, R. Murray, and G. F. Boudreaux-Bartels, " Wavelet transform-based QRS complex detector," *IEEE Trans. Biomed. Eng.*, vol. 46, pp. 838-848, July 1999.
- [10] C. Li, C. Zheng, and C. Tai, " Detection of ECG characteristic points using wavelet transforms," *IEEE Trans. Biomed. Eng.*, vol. 42, pp. 21-28, January 1995.
- [11] Z. Dokur, T. Ölmez, and E. Yazgan, "Comparison of discrete wavelet and Fourier transforms for ECG beat classification," *Electron. Lett.*,1999,35, (18) pp.1502-1504
- [12] M. Popescu, N. Laskaris, I. Chiladakis, C. Stathopoulos, P. Cristea, A.Manolis, and A. Bezerianos, "Beat-to-beat wavelet variance of the QRS complex as a marker of arrhythmogenic substrate in ventricular tachycardia patients," *Physiol. Meas.*, vol. 19, pp. 77-92, 1998.
- [13] A. Cohen, and D. Landsberg, " Adaptive real-time wavelet detection," *IEEE Trans. Biomed. Eng.*, vol. BME-30, NO. 6, pp. 332-340, June 1983.
- [14] U.Wiklund, M. Akay, and U. Niklasson, " Short-term analysis of heart-rate variability by adapted wavelet transforms, *IEEE Engineering in Medicine and Biology Society*, September/October 1997.
- [15] S. Mallat and S. Zhong, " Characterization of signals from multiscale edges," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 17, no.7, pp. 710-732, July 1992.
- [16] V. X. Afonso, W. J. Tompkins, T. Q. Nguyen, and S. Luo, " ECG beat detection using filter banks," *IEEE Trans. Biomed. Eng.*, vol. 46, pp. 192-202, February 1999.
- [17] M. Okada, "A digital filter for the QRS complex detection," *IEEE Trans. Biomed. Eng.*, vol. 26, pp. 700-703, December, 1979.
- [18] Y. Sun, S. Suppappola, T.A. Wrublewski, "Microcontroller-based real-time QRS detection," *Biomed. Instrum. Technol.*, vol. 26, no. 6, pp. 477-484, 1992.

- [19] S. Suppappola, Y. Sun, "Nonlinear transforms of ECG signals for digital QRS detection: A quantitative analysis," *IEEE Trans. Biomed. Eng.*, vol. 41, no. 4, pp. 397-400, April 1994.
- [20] P.S. Hamilton and W.J. Tompkins, " Quantitative investigation of QRS detection rules using the MIT/BIH arrhythmic database," *IEEE Trans. Biomed. Eng.*, vol. 33, pp. 1157-1165, 1986.
- [21] J. Pan and W.J. Tompkins, " A real-time QRS detection algorithm," *IEEE Trans. Biomed. Eng.*, vol. 32, pp. 230-236, 1985.
- [22] A. Ligtenberg and M. Kunt, " A robust digital QRS-detection algorithm for arrhythmia monitoring," *Comput. Biomed. Res.*, vol. 16, pp. 273-286, 1983.
- [23] Z. Dokur, T. Olmez, E. Yazgan and O.K. Ersoy, " Detection of ECG waveforms by neural networks," *Med. Eng. Phys.*, vol. 19, no. 8, pp. 738-741, 1997.
- [24] B.C. Yu, S. Liu, M. Lee, C.Z. Chen and B.N. Chiang, " A nonlinear digital filter for cardiac QRS complex detection," *J. Clin. Eng.*, vol. 10, pp. 193-201, 1985.
- [25] P.O. Börjesson, O. Pahlm, L. Sörnomo and M.-E. Nygards, " Adaptive QRS detection based on maximum a posteriori estimation," *IEEE Trans. Biomed. Eng.*, vol. 29, pp. 341-351, May 1982.
- [26] L. Sörnomo, O. Pahlm, and M.-E. Nygards, " Adaptive QRS detection: A study of performance," *IEEE Trans. Biomed. Eng.*, BME-32, pp. 392-401, June 1985.
- [27] L. Sörnomo, O. Pahlm, and M.-E. Nygards, " Adaptive QRS detection in ambulatory ECG monitoring: A study of performance," in *Computers in Cardiology*. Long Beach, CA: IEEE Computer Society, 1982, pp. 201-204.
- [28] W.A.H. Engelse and C. Zeelenberg, " A single scan algorithm for qrs-detection and feature extraction," in *Computers in Cardiology*. Long Beach, CA: IEEE Computer Society, 1979, pp. 37-42.
- [29] L. Keselbrener, M. Keselbrener and S. Akselrod, " Nonlinear high pass filter for R-wave detection in ECG signal," *Med. Eng. Phys.*, vol. 19, no. 5, pp. 481-484, 1997.
- [30] S.E. Fischer, S.A. Wickline and C.H. Lorenz, " Novel real-time R-wave detection algorithm based on the vectocardiogram for accurate gated magnetic resonance acquisitions," *Magn. Reson. Med.*, vol. 42, no. 2, pp. 361-370, 1999.
- [31] L. Khadra, A.S. Al-Fahoum and H. Al-Nashash, " Detection of life-threatening cardiac arrhythmias using the wavelet transformation," *Med. Biol. Eng. Comput.*, vol. 35, no. 6, pp. 626-632, 1997.
- [32] S. Mallat and W.L. Hwang, "Singularity detection and processing with wavelets," *IEEE Trans. Inform. Theory*, vol. 38., pp. 617-643, 1992.
- [33] M. Bahoura, M. Hassani and M. Hubin, " DSP implementation of wavelet transform for real time ECG wave forms detection and heart rate analysis," *Comput. Methods Programs Biomed.*, vol. 52, no. 1, pp. 35-44, 1997.
- [34] K.S. Khobragade and R.B. Deshmukh, "ECG analysis using wavelet transforms," *IETE J. Res.*, vol. 43, no. 6, pp. 423-432, 1997.
- [35] J.S. Sahambi, S.N. Tandon and R.K.P. Bhatt, "Using wavelet transforms for ECG characterization. An on-line digital signal processing system," *IEEE Eng. Med. Biol. Mag.*, vol. 16, pp. 77-83, 1997.
- [36] V. Di-Virgilio, C. Francaiancia, S. Lino and S. Cerutti, "ECG fiducial points detection through wavelet transform," in *1995 IEEE Eng. Med. Biol. 17th Ann. Conf. 21st Canadian Med. Biol. Eng. Conf.*, Montreal, Quebec, Canada, 1997, pp. 1051-1052.

- [37] K.D. Rao, "Dwt based detection of R-peaks and data compression of ECG signals," *IETE J. Res.*, vol. 43, no. 5, pp. 345-349, 1997.
- [38] S. Mallat, "Zero-crossing of a wavelet transform," *IEEE Trans. Inform. Theory*, vol. 37., pp. 1019-1033, 1991.
- [39] T.A. Gyaw and S.R. Ray, "The wavelet transform as a tool for recognition of biosignals," *Biomed. Sci. Instrum.*, vol. 30., pp. 63-68, 1994.
- [40] J.A. Crowe, N.M. Gibson, M.S. Woolfson and M.G. Somekh, "Wavelet transform as a potential tool for ECG analysis and compression," *J. Biomed. Eng.*, vol. 14., no.3, pp. 268-272, 1992.
- [41] G. Kokturk, "A real-time simulated QRS detection system constructed using wavelet filtering technique," in *Proc. IEEE-SP Int. Symp. Time-Frequency and Time-Scale Analysis*, Pittsburgh, PA, 1998, pp. 281-284.
- [42] C. May, N. Hubing and A.W. Hahn, "Wavelet transforms for electrocardiogram processing," *Biomed. Sci. Instrum.*, vol. 33., pp. 1-6, 1997.
- [43] S. Barro, M. Fernández-Delgado, J.A. Vila-Sobrino, C.V. Regueiro, E. Sánchez, "Classifying multichannel ECG patterns with an adaptive neural network," *IEEE Engineering in Medicine and Biology Society*, pp. 45-55, January/February 1998.
- [44] M. Fernández-Delgado and S.B. Ameneiro, "MART: A multichannel ART-based neural network," *IEEE Trans. Neural Networks*, vol. 9, pp. 139-150, 1998.
- [45] Q. Xue, Y.H. Hu, W.J. Tompkins, "Neural-network-based adaptive matched filtering for QRS detection," *IEEE Trans. Biomed. Eng.*, vol. 39, pp. 317-329, 1992.
- [46] Y. Suzuki, "Self-organizing QRS-wave recognition in ECG using neural network," *IEEE Trans. Neural Networks*, vol. 6, pp. 1469-1477, 1995.
- [47] S. Osowski, T.H. Linh, "ECG beat recognition using fuzzy hybrid neural network," *IEEE Trans. Biomed. Eng.*, vol. 48., no. 11, pp. 1265-1271, November 2001.
- [48] M. Lagerholm, C. Peterson, G. Braccini, L. Edenbrandt and L. Soernmo, "Clustering ECG complexes using Hermite functions and self-organizing maps," *IEEE Trans. Biomed. Eng.*, vol. 47, pp. 838-848, 2000.
- [49] G. Vijaya, V. Kumar and H.K. Verma, "ANN-based QRS-complex analysis of ECG," *J. Med. Eng. Technol.*, vol. 22., no. 4, pp. 160-167, 1998.
- [50] M.G. Strintzis, G. Stalidis, X. Magnisalis and N. Maglaveras, "Use of neural networks for electrocardiogram (ECG) feature extraction, recognition and classification," *Neural Netw. World*, vol. 3, no. 4, pp. 313-327, 1992.
- [51] P.S. Hamilton and W.J. Tompkins, "Adaptive matched filtering for QRS detection," in *Proc. Annu. Int. Conf. IEEE Engineering in Medicine and Biology Society*, New Orleans, LA, 1988, pp. 147-148.
- [52] A. Kyrkos, E. Giakoumakis and G. Carayannis, "Time recursive prediction technique on QRS detection problem," in *Proc. 9th Annu. Conf. IEEE Engineering in Medicine and Biology Society*, 13-16 Nov. 1987, Boston, MA, pp. 1885-1886.
- [53] K.P. Lin and W.H. Chang, "QRS feature extraction using linear prediction," *IEEE Trans. Biomed. Eng.*, vol. 36, pp. 1050-1055, 1989.
- [54] S. Dandapat and G.C. Ray, "Spike detection in biomedical signals using midprediction filter," *Med. Biol. Eng. Comput.*, vol. 35, no. 4, pp. 354-360, 1997.
- [55] P.E. Trahanias, "An approach to QRS complex detection using mathematical morphology," *IEEE Trans. Biomed. Eng.*, vol. 40, no. 2, pp. 201-205, February 1993.

- [56] C.-H.H. Chu and E.J. Delp, "Impulsive noise suppression and background normalization of electrocardiogram signals using morphological operators," *IEEE Trans. Biomed. Eng.*, vol. 36, pp. 262-273, 1989.
- [57] R. Poli, S. Cagnoni, G. Valli, "Genetic design of optimum linear and nonlinear QRS detectors," *IEEE Trans. Biomed. Eng.*, vol. 42, pp. 1137-1141, 1995.
- [58] M.-E. Nygard and L. Sörnmo, "Delineation of the QRS complex using the envelope of the ECG," *Med. Biol. Eng. Comput.*, vol. 21, 1983.
- [59] S.-K. Yhou, J.-T. Wang and J.-R. Xu, "The real-time detection of QRS-complex using the envelope of ECG," in *Proc. 10th Annu. Int. Conf. IEEE Engineering in Medicine and Biology Society*, New Orleans, LA, 1988, p. 38.
- [60] F. Gritzali, "Towards a generalized scheme for QRS detection in ECG waveforms," *Signal Processing*, vol. 15, pp. 183-192, 1988.
- [61] F. Gritzali, G. Frangakis and G. Papakonstantinou, "A comparison of the length and energy transformations for the QRS detection," in *Proc. 9th Annu. Conf. IEEE Engineering in Medicine and Biology Society*, Boston, MA, 1987, pp. 549-550.
- [62] G. Belforte, R. De Mori and F. Ferraris, "A contribution to the automatic processing of electrocardiograms using syntactic methods," *IEEE Trans. Biomed. Eng.*, vol. 26, pp. 125-136, 1979.
- [63] E.J. Ciaccio, S.M. Dunn and M. Akay, "Biosignal pattern recognition and interpretation systems," *IEEE Eng. Med. Biol. Mag.*, pp. 269-273, 1994.
- [64] G. Papakonstantinou, E. Skordalakis and F. Gritzali, "An attribute grammar for QRS detection," *Pattern Recognit.*, vol. 19, no. 4, pp. 297-303, 1986.
- [65] G. Papakonstantinou and F. Gritzali, "Syntactic filtering of ECG waveforms," *Comput. Biomed. Res.*, vol. 14, pp. 158-167, 1981.
- [66] P. Trahanias, E. Skordalakis, "Syntactic pattern recognition of the ECG," *IEEE Trans. Pattern Anal. Machine Intell.*, vol. 12, pp. 648-657, 1990.
- [67] K.S. Fu, "A step towards unification of syntactic and statistical pattern recognition," *IEEE Trans. Pattern Anal. Machine Intell.*, PAMI-5, pp. 200-205, 1983.
- [68] G. K. Papakonstantinou, "An interpreter of attribute grammar and its application to waveform analysis," *IEEE Trans. Software Eng.*, SE-7, pp. 297-283, May 1981.
- [69] J.K. Udupa and I. Murthy, "Syntactic approach to ECG rhythm analysis," *IEEE Trans. Biomed. Eng.*, BME-27, pp. 370-375, July 1980.
- [70] A. Ruha, S. Sallinen and S. Nissila, "A real-time microprocessor QRS detector system with a 1-ms timing accuracy for the measurement of ambulatory HRV," *IEEE Trans. Biomed. Eng.*, vol. 44, pp. 159-167, 1997.
- [71] D. Ebenezer and V. Krishnamurthy, "Wave digital matched filter for electrocardiogram preprocessing," *J. Biomed. Eng.*, vol. 15, no. 2, pp. 132-134, 1993.
- [72] K.G. Lindecrantz and H. Lilja, "New software QRS detector algorithm suitable for real-time application with low signal-to-noise ratios," *J. Biomed. Eng.*, vol. 10, no. 3, pp. 280-284, 1988.
- [73] S. Dobbs, N. Schmitt and H. Ozemek, "QRS detection by template matching using real-time correlation on a microcomputer," *J. Clin. Eng.*, vol. 9, no. 3, pp. 197-212, Sept. 1984.
- [74] Massachusetts Institute of Technology. MIT-BIH ECG database. Dostupna na adresi: <http://ecg.mit.edu/>.

- [75] R. Silipo, C. Marchesi, "Artificial neural networks for automatic ECG analysis," *IEEE Trans. Signal. Process.*, vol. 46, no. 5, pp. 1417-1425, May 1998.
- [76] M. Kundu, M. Nasipuri, D.K. Basu, "A knowledge-based approach to ECG interpretation using fuzzy logic," *IEEE Trans. Systems, man and cybernetics.*, vol. 28, no. 2, pp. 237-243, April 1998.
- [77] M.L. Ahlstrom and W.J. Tompkins, "Automated high-speed analysis of holter tapes with microcomputers," *IEEE Trans. Biomed. Eng.*, vol. 30, pp. 651-657, 1983
- [78] J. Fraden and M.R. Neumann, "QRS wave detection," *Med. Biol. Eng. Comput.*, vol. 18, pp. 125-132, 1980.
- [79] P. Morizet-Mahoudeaux, C. Moreau, D. Moreau and J.J. Quarante, "Simple microprocessor-based system for on-line ECG arrhythmia analysis," *Med. Biol. Eng. Comput.*, vol. 19, no. 4, pp. 497-501, July 1981.
- [80] T. Ölmez, "Classification of ECG waveforms by using RCE neural network and genetic algorithms," *Electron. Lett.*, vol. 33, no. 18, pp. 1561-1562, 1997.
- [81] J. Chen, S. Itoh, "A wavelet transform-based ECG compression method guaranteeing desired signal quality," *IEEE Trans. Biomed. Eng.*, vol. 45, pp. 1414-1419, 1998.
- [82] A.G. Ramakrishnan, and S. Saha, "ECG coding by wavelet-based linear prediction," *IEEE Trans. Biomed. Eng.*, vol. 44, no. 12, pp. 1253-1261, December 1997.
- [83] S. Olmos, and P. Laguna, "Steady-state MSE convergence of LMS adaptive filters with deterministic reference inputs with applications to biomedical signals," *IEEE Trans. Signal. Process.*, vol. 48, no. 8, pp. 2229-2241, August 2000..
- [84] J.P. Martínez, S. Olmos, and P. Laguna, "Evaluation of a wavelet-based ECG waveform detector on the QT database," In *Computers in Cardiology*, pp. 81-84, IEEE Computer Society Press, 2000.
- [85] N. Goldschlager, M.J. Goldman, *Elektrokardiografija, Interpretacija EKG-a, Savremena administracija*, Beograd, 1986.
- [86] J. Lewalle, "Tutorial of continuous wavelet analysis of experimental data," , April 1995., www.mame.syr.edu/faculty/lewallle/tutor/tutor.html
- [87] Popović D.B., Bojanić D., Jorgovanović N., Došen S., Petrović R., "TeleEKG based on Bluetooth transceivers", TELFOR, Beograd, 2002.
- [88] Bojanić D., Popović D.B., "QRS detektor koji se bazira na wavelet transformaciji", Zbornik radova XLVI konferencije ETRAN-a, Banja Vrućica-Teslić, 2002.
- [89] Bojanić D., Popović D.B., "QRS detection from an ongoing ECG recordings by using dyadic wavelets", 2nd European Medical and Biological Engineering Conference, Vienna, 2002.
- [90] N.V. Thakor, Y.S. Zhu, "Applications of adaptive filtering to ECG analysis: Noise cancellation and arrhythmia detection," *IEEE Trans. Biomed. Eng.*, vol. 38, no. 8, pp. 785-794, August 1991.
- [91] B. Köhler, C. Henning, R. Orglmeister, "The principles of software QRS detection," *IEEE Eng. Med. Biol. Mag.*, vol. 21, no. 1, pp. 42-57, January/February 2002.